

Data Warehouse Macrofinanciero
Proyecto Guiado A→Z

Francisco Ramírez

12 de junio de 2026

Índice general

1. Hito 1: Creación del Proyecto	7
1.1. Objetivo	7
1.2. Resultado esperado	7
1.3. Paso 1: Crear la carpeta del proyecto	8
1.4. Paso 2: Abrir el proyecto en VS Code	8
1.5. Paso 3: Inicializar Git	8
1.6. Paso 4: Crear la estructura de carpetas	9
1.7. Paso 5: Crear los archivos iniciales	9
1.8. Paso 6: Configurar el archivo .gitignore	10
1.9. Paso 7: Crear el README inicial	10
1.10. Paso 8: Crear el entorno virtual	11
1.11. Paso 9: Instalar dependencias mínimas	11
1.12. Paso 10: Realizar el primer commit	11
1.13. Checklist de validación	12
1.14. Entregable	12
1.15. Próximo hito	13
2. Hito 2: Instalación y Configuración de PostgreSQL	14
2.1. Objetivo	14
2.2. Resultado esperado	14
2.3. Paso 1: Verificar instalación de PostgreSQL	15
2.4. Paso 2: Iniciar PostgreSQL	15
2.5. Paso 3: Conectarse al servidor	15
2.6. Paso 4: Crear la base de datos	16
2.7. Paso 5: Conectarse a la nueva base	16
2.8. Paso 6: Crear archivo .env	16
2.9. Paso 7: Actualizar .env.example	17
2.10. Paso 8: Crear módulo de conexión	17
2.11. Paso 9: Probar la conexión	18

2.12. Paso 10: Realizar una consulta desde Python	18
2.13. Paso 11: Instalar extensiones de VS Code	18
2.14. Paso 12: Crear primer script SQL	19
2.15. Checklist de validación	19
2.16. Entregable	19
2.17. Próximo hito	20
3. Hito 2: Configuración de DuckDB como Base de Datos Analítica Local	21
3.1. Objetivo	21
3.2. Resultado esperado	22
3.3. ¿Por qué DuckDB?	22
3.4. Arquitectura del hito	22
3.5. Paso 1: Actualizar la estructura del proyecto	23
3.6. Paso 2: Instalar DuckDB	23
3.7. Paso 3: Verificar instalación	24
3.8. Paso 4: Crear archivo de configuración	24
3.9. Paso 5: Actualizar .env.example	24
3.10. Paso 6: Crear módulo de conexión	25
3.11. Paso 7: Ejecutar prueba de conexión	26
3.12. Paso 8: Verificar archivo de base de datos	26
3.13. Paso 9: Crear primer script SQL	26
3.14. Paso 10: Ejecutar SQL desde Python	27
3.15. Paso 11: Instalar extensión recomendada en VS Code	27
3.16. Paso 12: Crear consulta de prueba	28
3.17. Diferencias importantes frente a PostgreSQL	28
3.18. Buenas prácticas	29
3.19. Checklist de validación	29
3.20. Entregable	30
3.21. Próximo hito	30
4. Hito 3: Diseño de las Fuentes de Datos e Ingesta Inicial	31
4.1. Objetivo	31
4.2. ¿Por qué comenzamos con archivos CSV?	31
4.3. Arquitectura de la ingesta	32
4.4. Fuentes utilizadas	33
4.4.1. Fuente 1: Tipo de Cambio	33
4.4.2. Fuente 2: Balances Bancarios	33
4.5. Paso 1: Crear estructura de almacenamiento	34
4.6. Paso 2: Crear archivo tipo_cambio.csv	34

4.7. Paso 3: Crear archivo balances.csv	35
4.8. Paso 4: Crear script de exploración	35
4.9. Paso 5: Ejecutar exploración	36
4.10. Paso 6: Verificar estructura	36
4.11. Paso 7: Validaciones básicas	36
4.12. Paso 8: Crear capa processed	37
4.13. Paso 9: Guardar datos procesados	37
4.14. Paso 10: Documentar las fuentes	37
4.15. Entregables	38
4.16. Checklist de validación	38
4.17. Próximo hito	39
5. Hito 4: Diseño del Modelo Dimensional	40
5.1. Objetivo	40
5.2. Resultado esperado	40
5.3. Paso 1: Entender qué es un modelo dimensional	41
5.4. Paso 2: Identificar los procesos de negocio	41
5.5. Paso 3: Definir el grano	41
5.5.1. Grano de fact_tipo_cambio	42
5.5.2. Grano de fact_balance_mensual	42
5.6. Paso 4: Definir dimensiones	42
5.6.1. Dimensión tiempo	42
5.6.2. Dimensión moneda	43
5.6.3. Dimensión entidad financiera	43
5.7. Paso 5: Definir tablas de hechos	43
5.7.1. Hecho tipo de cambio	43
5.7.2. Hecho balance mensual	44
5.8. Paso 6: Definir claves	44
5.8.1. Clave de negocio	44
5.8.2. Clave subrogada	45
5.9. Paso 7: Diseñar el esquema estrella	45
5.10. Paso 8: Crear documento del modelo	46
5.11. Paso 9: Crear tabla de definición del modelo	47
5.12. Paso 10: Definir indicadores derivados	47
5.13. Paso 11: Validar el diseño	48
5.14. Checklist de validación	48
5.15. Entregable	49
5.16. Próximo hito	49

6. Hito 5: Construcción de la Capa Staging (Bronze)	50
6.1. Objetivo	50
6.2. Resultado esperado	50
6.3. ¿Qué es la capa Staging?	51
6.4. Arquitectura del Data Warehouse	51
6.5. Paso 1: Crear carpeta para scripts SQL	52
6.6. Paso 2: Crear los schemas	52
6.7. Paso 3: Ejecutar el script	52
6.8. Paso 4: Crear script de tablas staging	53
6.9. Paso 5: Diseñar tabla tipo_cambio_raw	53
6.10. ¿Por qué usamos TEXT?	53
6.11. Paso 6: Diseñar tabla balance_bancario_raw	54
6.12. Paso 7: Ejecutar el DDL	55
6.13. Paso 8: Verificar tablas creadas	55
6.14. Paso 9: Inspeccionar estructura	55
6.15. Paso 10: Crear script de prueba	55
6.16. Paso 11: Documentar la capa staging	56
6.17. Paso 12: Crear consulta de monitoreo	57
6.18. Buenas prácticas	57
6.19. Checklist de validación	57
6.20. Entregable	58
6.21. Próximo hito	58
7. Hito 5: Construcción de la Capa Staging en DuckDB	59
7.1. Objetivo	59
7.2. Resultado esperado	59
7.3. Paso 1: Crear script de schemas	60
7.4. Paso 2: Crear script para ejecutar SQL	60
7.5. Paso 3: Ejecutar creación de schemas	61
7.6. Paso 4: Verificar schemas	61
7.7. Paso 5: Crear script de tablas staging	62
7.8. Paso 6: Crear tabla tipo_cambio_raw	62
7.9. Paso 7: Crear tabla balance_bancario_raw	63
7.10. Nota sobre tipos de datos	63
7.11. Paso 8: Ejecutar DDL de staging	64
7.12. Paso 9: Verificar tablas creadas	64
7.13. Paso 10: Crear script general para inicializar la base	65
7.14. Paso 11: Ejecutar inicialización completa	66
7.15. Paso 12: Crear consulta de monitoreo	66
7.16. Buenas prácticas	66

7.17. Checklist de validación	67
7.18. Entregable	67
7.19. Próximo hito	68
8. Hito 6: Construcción del Primer Proceso ETL	69
8.1. Objetivo	69
8.2. Resultado esperado	70
8.3. Arquitectura del proceso	70
8.4. Paso 1: Verificar archivos fuente	70
8.5. Paso 2: Crear módulo de conexión	71
8.6. Paso 3: Crear script de carga	71
8.7. Paso 4: Importar librerías	71
8.8. Paso 5: Leer tipo de cambio	72
8.9. Paso 6: Leer balances	72
8.10. Paso 7: Agregar metadatos	72
8.11. Paso 8: Limpiar staging antes de cargar	73
8.12. Paso 9: Ejecutar truncado desde Python	73
8.13. Paso 10: Cargar tipo de cambio	73
8.14. Paso 11: Cargar balances	74
8.15. Paso 12: Confirmar carga	74
8.16. Versión completa del script	74
8.17. Paso 13: Ejecutar ETL	76
8.18. Paso 14: Verificar en PostgreSQL	76
8.19. Paso 15: Inspeccionar datos	76
8.20. Paso 16: Crear script de validación	77
8.21. Paso 17: Crear orquestador	77
8.22. Buenas prácticas	78
8.23. Checklist de validación	78
8.24. Entregable	78
8.25. Próximo hito	79
9. Hito 6: Construcción del Primer Proceso ETL con DuckDB	80
9.1. Objetivo	80
9.2. Resultado esperado	81
9.3. Arquitectura del proceso	81
9.4. Paso 1: Verificar archivos fuente	81
9.5. Paso 2: Verificar conexión	81
9.6. Paso 3: Crear script de carga	82
9.7. Paso 4: Importar librerías	82
9.8. Paso 5: Leer tipo de cambio	82

9.9. Paso 6: Leer balances	83
9.10. Paso 7: Agregar metadatos	83
9.11. Paso 8: Conectarse a DuckDB	84
9.12. Paso 9: Limpiar staging	84
9.13. Paso 10: Registrar DataFrames	84
9.14. Paso 11: Cargar tipo de cambio	85
9.15. Paso 12: Cargar balances	85
9.16. Paso 13: Verificar conteos	85
9.17. Paso 14: Cerrar conexión	86
9.18. Versión completa del script	86
9.19. Paso 15: Ejecutar ETL	89
9.20. Paso 16: Crear consulta de monitoreo	89
9.21. Paso 17: Ejecutar consulta	90
9.22. Paso 18: Crear orquestador	90
9.23. Buenas prácticas	91
9.24. Checklist de validación	91
9.25. Entregable	91
9.26. Próximo hito	92

10.Hito 7: Construcción de la Capa Core y Dimensiones en DuckDB	93
10.1. Objetivo	93
10.2. Resultado esperado	94
10.3. Arquitectura del hito	94
10.4. Paso 1: Crear script de dimensiones	94
10.5. Paso 2: Crear dimensión tiempo	94
10.6. Paso 3: Crear dimensión moneda	95
10.7. Paso 4: Crear dimensión entidad financiera	95
10.8. Paso 5: Ejecutar DDL	96
10.9. Paso 6: Crear script de carga	97
10.10 Paso 7: Limpiar dimensiones	97
10.11 Paso 8: Poblar dimensión tiempo	97
10.12 Explicación	98
10.13 Paso 9: Poblar dimensión moneda	98
10.14 Paso 10: Poblar dimensión entidad financiera	99
10.15 Nota sobre SCD Tipo 2	101
10.16 Paso 11: Ejecutar carga	101
10.17 Paso 12: Verificar dimensión tiempo	102
10.18 Paso 13: Verificar dimensión moneda	102
10.19 Paso 14: Verificar dimensión entidad financiera	102

10.20	Paso 15: Crear consulta de monitoreo	103
10.21	Paso 16: Ejecutar monitoreo	104
10.22	Paso 17: Integrar al pipeline	104
10.23	Buenas prácticas	105
10.24	Checklist de validación	105
10.25	Entregable	105
10.26	Próximo hito	106

Capítulo 1

Hito 1: Creación del Proyecto

1.1. Objetivo

El objetivo de este hito es construir la estructura inicial del proyecto y preparar el entorno de desarrollo que utilizaremos durante todo el manual.

Al finalizar este hito el estudiante tendrá:

- Un repositorio Git inicializado.
- Una estructura de carpetas profesional.
- Un entorno virtual de Python.
- Dependencias básicas instaladas.
- El primer commit del proyecto.

1.2. Resultado esperado

Al finalizar este hito, la estructura del proyecto deberá lucir de la siguiente forma:

```
dwh_macrofinanciero_rd/  
  
+-- data/  
|   +-- raw/  
|   \-- processed/  
  
+-- sql/
```

```
+++ etl/  
+++ app/  
+++ docs/  
+++ tests/  
  
+++ README.md  
+++ requirements.txt  
+++ .gitignore
```

1.3. Paso 1: Crear la carpeta del proyecto

Abrir PowerShell y navegar al directorio donde se almacenará el proyecto.

Por ejemplo:

```
cd C:\Users\t490\Documents\MacroPol
```

Crear la carpeta principal:

```
mkdir dwh_macrofinanciero_rd  
cd dwh_macrofinanciero_rd
```

Verificar la ubicación actual:

```
pwd
```

1.4. Paso 2: Abrir el proyecto en VS Code

Desde la terminal:

```
code .
```

VS Code deberá abrir la carpeta recién creada.

1.5. Paso 3: Inicializar Git

Abrir la terminal integrada de VS Code y ejecutar:

```
git init
```

Salida esperada:

```
Initialized empty Git repository
```

Verificar el estado:

```
git status
```

1.6. Paso 4: Crear la estructura de carpetas

Crear las carpetas principales:

```
mkdir data
mkdir sql
mkdir etl
mkdir app
mkdir docs
mkdir tests
```

Crear las subcarpetas para almacenamiento de datos:

```
mkdir data\raw
mkdir data\processed
```

1.7. Paso 5: Crear los archivos iniciales

Crear los siguientes archivos:

- README.md
- requirements.txt
- .gitignore
- .env.example

La estructura del proyecto deberá verse así:

```
dwh_macrofinanciero_rd/
|
+-- data/
+-- sql/
+-- etl/
+-- app/
+-- docs/
+-- tests/
|
+-- README.md
+-- requirements.txt
+-- .gitignore
+-- .env.example
```

1.8. Paso 6: Configurar el archivo .gitignore

Crear el archivo:

```
.gitignore
```

con el siguiente contenido:

```
.venv/  
.env  
  
**pycache**/  
  
*.pyc  
*.pyo  
  
.vscode/  
  
data/processed/  
  
.DS_Store  
Thumbs.db
```

1.9. Paso 7: Crear el README inicial

Archivo:

```
README.md
```

Contenido sugerido:

```
# Data Warehouse Macrofinanciero RD  
  
Proyecto practico para construir una plataforma  
de inteligencia macrofinanciera utilizando:  
  
* PostgreSQL  
* Python  
* Streamlit  
* GitHub
```

Autor: Francisco Ramirez

1.10. Paso 8: Crear el entorno virtual

Crear el entorno virtual:

```
python -m venv .venv
```

Activarlo:

Windows:

```
.venv\Scripts\activate
```

Linux/Mac:

```
source .venv/bin/activate
```

La terminal deberá mostrar:

```
(.venv)
```

1.11. Paso 9: Instalar dependencias mínimas

Instalar los paquetes necesarios:

```
pip install pandas  
pip install sqlalchemy  
pip install psycopg2-binary  
pip install python-dotenv
```

Guardar las dependencias instaladas:

```
pip freeze > requirements.txt
```

1.12. Paso 10: Realizar el primer commit

Agregar todos los archivos al repositorio:

```
git add .
```

Verificar:

```
git status
```

Crear el primer commit:

```
git commit -m "Initial_project_structure"
```

Consultar el historial:

```
git log --oneline
```

Salida esperada:

```
3f2a9ab Initial project structure
```

1.13. Checklist de validación

Antes de continuar al siguiente hito, verificar:

- ☐ VS Code instalado y funcionando.
- ☐ Proyecto creado.
- ☐ Git inicializado.
- ☐ Estructura de carpetas creada.
- ☐ Entorno virtual activo.
- ☐ Dependencias instaladas.
- ☐ Primer commit realizado.

1.14. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Un proyecto abierto en VS Code.
- Un repositorio Git funcional.
- Un entorno virtual configurado.
- Una estructura base lista para desarrollar el Data Warehouse.

1.15. Próximo hito

En el Hito 2 construiremos la infraestructura de base de datos:

- Instalación de PostgreSQL.
- Creación de la base de datos.
- Configuración de variables de entorno.
- Primera conexión Python → PostgreSQL.

Capítulo 2

Hito 2: Instalación y Configuración de PostgreSQL

2.1. Objetivo

El objetivo de este hito es preparar el motor de base de datos que servirá como núcleo del Data Warehouse macrofinanciero.

Al finalizar este hito el estudiante será capaz de:

- Instalar PostgreSQL.
- Crear una base de datos para el proyecto.
- Conectarse desde VS Code.
- Configurar variables de entorno.
- Conectarse desde Python.
- Ejecutar consultas SQL básicas.

2.2. Resultado esperado

Al finalizar este hito deberá existir:

- Una instancia funcional de PostgreSQL.
- Una base de datos llamada **macrofinanzas**.
- Un usuario con permisos adecuados.

CAPÍTULO 2. HITO 2: INSTALACIÓN Y CONFIGURACIÓN DE POSTGRESQL16

- Un archivo `.env` para gestionar credenciales.
- Un script Python capaz de conectarse a la base de datos.

2.3. Paso 1: Verificar instalación de PostgreSQL

Abrir PowerShell y ejecutar:

```
psql --version
```

Salida esperada:

```
psql (PostgreSQL) 17.x
```

Si el comando no funciona:

- Verificar que PostgreSQL está instalado.
- Verificar que el directorio `bin` está en el `PATH`.

2.4. Paso 2: Iniciar PostgreSQL

Verificar que el servicio está activo.

En Windows:

1. Abrir Servicios.
2. Buscar PostgreSQL.
3. Verificar estado Running".

Alternativamente:

```
net start postgresql-x64-17
```

2.5. Paso 3: Conectarse al servidor

Abrir terminal:

```
psql -U postgres
```

Introducir la contraseña configurada durante la instalación.

Debería aparecer:

```
postgres=#
```

2.6. Paso 4: Crear la base de datos

Ejecutar:

```
CREATE DATABASE macrofinanzas;
```

Verificar:

```
\l
```

La nueva base deberá aparecer en la lista.

Salir:

```
\q
```

2.7. Paso 5: Conectarse a la nueva base

```
psql -U postgres -d macrofinanzas
```

Verificar:

```
SELECT current_database();
```

Resultado esperado:

```
macrofinanzas
```

2.8. Paso 6: Crear archivo .env

En la raíz del proyecto crear:

```
.env
```

Contenido:

```
DB_HOST=localhost  
DB_PORT=5432  
DB_NAME=macrofinanzas  
DB_USER=postgres  
DB_PASSWORD=tu_password
```

Importante:

El archivo `.env` nunca debe enviarse a GitHub.

2.9. Paso 7: Actualizar .env.example

Crear una versión pública:

`.env.example`

Contenido:

```
DB_HOST=localhost
DB_PORT=5432
DB_NAME=macrofinanzas
DB_USER=postgres
DB_PASSWORD=your_password
```

Este archivo sí puede subirse al repositorio.

2.10. Paso 8: Crear módulo de conexión

Crear:

`etl/db.py`

```
from sqlalchemy import create_engine
from dotenv import load_dotenv
import os

load_dotenv()

HOST = os.getenv("DB_HOST")
PORT = os.getenv("DB_PORT")
DB = os.getenv("DB_NAME")
USER = os.getenv("DB_USER")
PASSWORD = os.getenv("DB_PASSWORD")

connection_string = (
    f"postgresql+psycopg2://{USER}:{PASSWORD}@{HOST}:{PORT}/{DB}"
)

engine = create_engine(connection_string)

print("Conexion_creada_correctamente.")
```

2.11. Paso 9: Probar la conexión

Ejecutar:

```
python etl/db.py
```

Salida esperada:

```
Conexión creada correctamente.
```

2.12. Paso 10: Realizar una consulta desde Python

Modificar temporalmente:

```
from sqlalchemy import text

with engine.connect() as conn:
    resultado = conn.execute(
        text("SELECT version();")
    )

    '''
    for fila in resultado:
        print(fila)
    '''
```

Ejecutar nuevamente:

```
python etl/db.py
```

Resultado esperado:

```
PostgreSQL 17.x ...
```

2.13. Paso 11: Instalar extensiones de VS Code

Instalar:

- PostgreSQL
- SQLTools
- SQLTools PostgreSQL Driver

Estas extensiones facilitarán la ejecución de consultas y exploración de objetos.

2.14. Paso 12: Crear primer script SQL

Crear:

`sql/test_connection.sql`

Contenido:

SELECT current_database();

SELECT current_user;

SELECT version();

Ejecutarlo desde VS Code o psql.

2.15. Checklist de validación

Antes de continuar verificar:

- ☐ PostgreSQL instalado.
- ☐ Servicio iniciado.
- ☐ Base de datos creada.
- ☐ Archivo .env configurado.
- ☐ Python conectado a PostgreSQL.
- ☐ Consulta SQL ejecutada correctamente.

2.16. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Base de datos **macrofinanzas**.
- Módulo de conexión Python.
- Variables de entorno configuradas.
- VS Code conectado a PostgreSQL.
- Primer script SQL ejecutado exitosamente.

2.17. Próximo hito

En el Hito 3 construiremos la primera capa de datos:

- Diseño de las fuentes.
- Creación de datos simulados.
- Organización de carpetas **raw** y **processed**.
- Primera ingesta hacia PostgreSQL.

Capítulo 3

Hito 2: Configuración de DuckDB como Base de Datos Analítica Local

3.1. Objetivo

El objetivo de este hito es preparar la base de datos analítica que servirá como núcleo del proyecto.

A diferencia de PostgreSQL, DuckDB no requiere instalación como servicio ni privilegios de administrador. La base de datos se almacena como un archivo local dentro del proyecto, lo cual la convierte en una excelente opción para trabajar en laptops corporativas con restricciones de instalación.

Al finalizar este hito el estudiante será capaz de:

- Instalar DuckDB desde Python.
- Crear una base de datos local en formato `.duckdb`.
- Conectarse a DuckDB desde Python.
- Ejecutar consultas SQL básicas.
- Crear un módulo reutilizable de conexión.
- Verificar que el proyecto puede operar sin PostgreSQL.

3.2. Resultado esperado

Al finalizar este hito deberá existir una base de datos local:

```
data/warehouse/macrofinanzas.duckdb
```

y un archivo de conexión:

```
etl/db.py
```

capaz de abrir la base de datos desde Python.

3.3. ¿Por qué DuckDB?

DuckDB es una base de datos analítica embebida.

Esto significa que:

- No requiere servidor.
- No requiere instalación con privilegios de administrador.
- No necesita usuarios ni contraseñas.
- Puede vivir como un archivo dentro del proyecto.
- Se integra directamente con Python, Pandas y Streamlit.
- Es muy eficiente para consultas analíticas.

En este proyecto utilizaremos DuckDB como motor local para construir el Data Warehouse macrofinanciero.

3.4. Arquitectura del hito

La nueva arquitectura será:

```
CSV
|
V
Python
|
V
```


CAPÍTULO 3. HITO 2: CONFIGURACIÓN DE DUCKDB COMO BASE DE DATOS ANALÍTICA LO

```
DuckDB
|
V
Streamlit
```

La base quedará almacenada como archivo:

```
macrofinanzas.duckdb
```

3.5. Paso 1: Actualizar la estructura del proyecto

Dentro del proyecto crear la carpeta:

```
data/warehouse
```

En PowerShell:

```
mkdir data\warehouse
```

La estructura deberá quedar así:

```
dwh_macrofinanciero_rd/

+-- data/
|   +-- raw/
|   +-- processed/
|   -- warehouse/

+-- sql/
+-- etl/
+-- app/
+-- docs/
+-- tests/
```

3.6. Paso 2: Instalar DuckDB

Con el entorno virtual activo:

```
pip install duckdb
```

También instalaremos paquetes que utilizaremos en el proyecto:

```
pip install pandas
pip install python-dotenv
```

Guardar dependencias:

```
pip freeze > requirements.txt
```

3.7. Paso 3: Verificar instalación

Ejecutar:

```
python
```

Dentro de Python:

```
import duckdb
```

```
print(duckdb.**version**)
```

Salir:

```
exit()
```

Si se imprime la versión, DuckDB está correctamente instalado.

3.8. Paso 4: Crear archivo de configuración

Aunque DuckDB no requiere usuario ni contraseña, utilizaremos un archivo `.env` para mantener centralizada la ruta de la base.

Crear:

```
.env
```

Contenido:

```
DUCKDB_PATH=data/warehouse/macrofinanzas.duckdb
```

Importante: el archivo `.env` no debe subirse a GitHub.

3.9. Paso 5: Actualizar `.env.example`

Crear o actualizar:

```
.env.example
```

CAPÍTULO 3. HITO 2: CONFIGURACIÓN DE DUCKDB COMO BASE DE DATOS ANALÍTICA LO

Contenido:

DUCKDB_PATH=data/warehouse/macrofinanzas.duckdb

Este archivo sí puede subirse al repositorio.

3.10. Paso 6: Crear módulo de conexión

Crear:

etl/db.py

Contenido:

```
import os
import duckdb

from dotenv import load_dotenv

load_dotenv()

DB_PATH = os.getenv(
    "DUCKDB_PATH",
    "data/warehouse/macrofinanzas.duckdb"
)

def get_connection():
    conn = duckdb.connect(DB_PATH)
    return conn

if __name__ == "__main__":
    conn = get_connection()

    """
    result = conn.execute(
        "SELECT_ 'DuckDB_conectado_correctamente '_AS_mensaje;"
    ).fetchdf()

    print(result)

    conn.close()
    """
```

3.11. Paso 7: Ejecutar prueba de conexión

Desde la terminal:

```
python etl/db.py
```

Salida esperada:

```
mensaje
0 DuckDB conectado correctamente
```

Al ejecutar este script, DuckDB creará automáticamente el archivo:

```
data/warehouse/macrofinanzas.duckdb
```

3.12. Paso 8: Verificar archivo de base de datos

Confirmar que existe:

```
data/warehouse/macrofinanzas.duckdb
```

En PowerShell:

```
dir data\warehouse
```

Deberá aparecer el archivo `macrofinanzas.duckdb`.

3.13. Paso 9: Crear primer script SQL

Crear:

```
sql/test_connection.sql
```

Contenido:

```
SELECT
'DuckDB' AS motor,
current_database() AS base_actual;
```

3.14. Paso 10: Ejecutar SQL desde Python

Crear:

etl/run_sql_file.py

Contenido:

```
from db import get_connection

def run_sql_file(path):
    conn = get_connection()

    """
    with open(path, "r", encoding="utf-8") as file:
        sql = file.read()

    result = conn.execute(sql).fetchdf()

    print(result)

    conn.close()
    """

if __name__ == "__main__":
    run_sql_file(
        "sql/test_connection.sql"
    )
```

Ejecutar:

```
python etl/run_sql_file.py
```

Salida esperada:

```
motor          base_actual
0  DuckDB      macrofinanzas
```

3.15. Paso 11: Instalar extensión recomendada en VS Code

Buscar e instalar en VS Code:

CAPÍTULO 3. HITO 2: CONFIGURACIÓN DE DUCKDB COMO BASE DE DATOS ANALÍTICA LOCAL

- DuckDB SQL Tools
- Python

Esto permitirá explorar archivos DuckDB y ejecutar consultas desde el editor.

3.16. Paso 12: Crear consulta de prueba

Crear:

`sql/check_duckdb.sql`

Contenido:

```
SELECT  
1 AS prueba ,  
'ok' AS estado ;
```

Modificar temporalmente `etl/run_sql_file.py` para ejecutar este archivo o reutilizar la función:

```
run_sql_file(  
    "sql/check_duckdb.sql"  
)
```

3.17. Diferencias importantes frente a PostgreSQL

Al usar DuckDB, algunas cosas cambian:

- No necesitamos servidor.
- No necesitamos usuarios.
- No usamos contraseñas.
- No dependemos del puerto 5432.
- La base vive en un archivo.
- El proyecto es más portable.

Sin embargo, mantendremos la lógica conceptual del Data Warehouse:

CAPÍTULO 3. HITO 2: CONFIGURACIÓN DE DUCKDB COMO BASE DE DATOS ANALÍTICA LO

staging -> core -> mart

DuckDB soporta schemas, por lo que seguiremos trabajando con:

- staging
- core
- mart

3.18. Buenas prácticas

Durante este proyecto seguiremos estas reglas:

1. La base DuckDB se guardará en **data/warehouse**.
2. El archivo **.env** guardará la ruta local.
3. El archivo **.env.example** documentará la configuración.
4. El módulo **etl/db.py** será el único responsable de abrir conexiones.
5. Cada script cerrará la conexión al finalizar.

3.19. Checklist de validación

Antes de continuar verificar:

- ☐ Carpeta **data/warehouse** creada.
- ☐ DuckDB instalado.
- ☐ Archivo **.env** creado.
- ☐ Archivo **.env.example** actualizado.
- ☐ Módulo **etl/db.py** creado.
- ☐ Script **etl/db.py** ejecutado correctamente.
- ☐ Archivo **macrofinanzas.duckdb** generado.
- ☐ Script SQL de prueba ejecutado.

3.20. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Una base DuckDB local.
- Un módulo de conexión reutilizable.
- Una carpeta `data/warehouse`.
- Un archivo `.env.example`.
- Un mecanismo básico para ejecutar SQL desde Python.

3.21. Próximo hito

En el Hito 3 trabajaremos con las primeras fuentes de datos del proyecto. Construiremos:

- Archivos CSV iniciales.
- Lectura desde Python.
- Validaciones básicas.
- Organización de datos crudos y procesados.

Capítulo 4

Hito 3: Diseño de las Fuentes de Datos e Ingesta Inicial

4.1. Objetivo

El objetivo de este hito es construir la primera capa del flujo de datos. Al finalizar este hito el estudiante será capaz de:

- Comprender las fuentes de información del proyecto.
- Diseñar datasets alineados con las necesidades de negocio.
- Organizar correctamente las carpetas de datos.
- Crear archivos CSV simulados.
- Leer datos desde Python.
- Realizar validaciones básicas antes de cargar a PostgreSQL.

4.2. ¿Por qué comenzamos con archivos CSV?

En proyectos reales los datos suelen provenir de:

- APIs.
- Bases de datos.
- Excel.

- CSV.
- Servicios web.
- Plataformas regulatorias.

Sin embargo, durante las primeras etapas del proyecto es recomendable trabajar con archivos CSV.

Esto permite:

- Diseñar el modelo de datos.
- Construir el ETL.
- Validar la arquitectura.
- Evitar complejidad innecesaria.

Una vez validado el proceso, sustituiremos los CSV por fuentes reales.

4.3. Arquitectura de la ingesta

El flujo de trabajo será:

```
Fuente CSV
|
V
data/raw
|
V
Python
|
V
Validación
|
V
data/processed
|
V
PostgreSQL
```

4.4. Fuentes utilizadas

El proyecto utilizará dos fuentes principales.

4.4.1. Fuente 1: Tipo de Cambio

Representa información similar a la publicada por el Banco Central.

Grano:

Una observación por fecha y moneda.

Variables:

- fecha
- moneda
- tasa_compra
- tasa_venta

Ejemplo:

```
fecha,moneda,tasa_compra,tasa_venta
2024-01-01,USD,58.50,58.80
2024-01-01,EUR,63.10,63.60
```

4.4.2. Fuente 2: Balances Bancarios

Representa información similar a la publicada por la Superintendencia de Bancos.

Grano:

Una observación por mes y entidad.

Variables:

- periodo
- entidad_cod
- entidad_nombre
- tipo_entidad

- activos_totales
- cartera_creditos
- depositos
- patrimonio
- resultado_neto
- depositos_me
- cartera_me

Ejemplo:

```
periodo,entidad_cod,activos_totales
202401,B001,120000000
```

4.5. Paso 1: Crear estructura de almacenamiento

Verificar que existe:

```
data/
```

```
+-- raw/
```

```
+-- processed/
```

`raw` contendrá los datos originales.

`processed` contendrá los datos validados.

4.6. Paso 2: Crear archivo tipo_cambio.csv

Crear:

```
data/raw/tipo_cambio.csv
```

Contenido mínimo:

```
fecha,moneda,tasa_compra,tasa_venta
2024-01-01,USD,58.50,58.80
2024-01-02,USD,58.55,58.85
2024-01-03,USD,58.60,58.90
2024-01-01,EUR,63.10,63.60
2024-01-02,EUR,63.20,63.70
```

4.7. Paso 3: Crear archivo balances.csv

Crear:

data/raw/balances.csv

Contenido mínimo:

```
periodo,entidad_cod,entidad_nombre,  
tipo_entidad,activos_totales,  
cartera_creditos,depositos,  
patrimonio,resultado_netto,  
depositos_me,cartera_me
```

```
202401,B001,Banco Alfa,  
Banco Multiple,120000000,  
85000000,95000000,  
15000000,1200000,  
25000000,18000000
```

4.8. Paso 4: Crear script de exploración

Crear:

etl/explore_sources.py

```
import pandas as pd  
  
fx = pd.read_csv(  
    "data/raw/tipo_cambio.csv"  
)  
  
balances = pd.read_csv(  
    "data/raw/balances.csv"  
)  
  
print("\nTipo_de_Cambio")  
print(fx.head())  
  
print("\nBalances")  
print(balances.head())
```

4.9. Paso 5: Ejecutar exploración

Ejecutar:

```
python etl/explore_sources.py
```

Resultado esperado:

- Visualización de las primeras filas.
- Confirmación de lectura correcta.

4.10. Paso 6: Verificar estructura

Agregar:

```
print(fx.info())
```

```
print(balances.info())
```

Analizar:

- Número de filas.
- Número de columnas.
- Tipos de datos.
- Valores faltantes.

4.11. Paso 7: Validaciones básicas

Agregar:

```
print(
fx.isnull().sum()
)
```

```
print(
balances.isnull().sum()
)
```

Verificar:

- Valores nulos.

- Fechas inválidas.
- Tasas negativas.

4.12. Paso 8: Crear capa processed

Convertir tipos de datos:

```
fx["fecha"] = pd.to_datetime(
fx["fecha"]
)

fx["tasa_compra"] = (
fx["tasa_compra"]
. astype(float)
)

fx["tasa_venta"] = (
fx["tasa_venta"]
. astype(float)
)
```

4.13. Paso 9: Guardar datos procesados

```
fx.to_csv(
"data/processed/tipo_cambio.csv",
index=False
)

balances.to_csv(
"data/processed/balances.csv",
index=False
)
```

4.14. Paso 10: Documentar las fuentes

Crear:

```
docs/data_dictionary.md
```

Documentar:

- Nombre de variable.
- Descripción.
- Tipo de dato.
- Fuente.
- Frecuencia.

4.15. Entregables

Al finalizar este hito deberá existir:

- Archivos CSV en raw.
- Archivos validados en processed.
- Script de exploración.
- Diccionario de datos.
- Validaciones básicas implementadas.

4.16. Checklist de validación

- ☐ Existe carpeta raw.
- ☐ Existe carpeta processed.
- ☐ tipo_cambio.csv creado.
- ☐ balances.csv creado.
- ☐ Python puede leer ambos archivos.
- ☐ Validaciones ejecutadas.
- ☐ Archivos procesados generados.

4.17. Próximo hito

En el Hito 4 diseñaremos el modelo dimensional.
Construiremos:

- Dimensión Tiempo.
- Dimensión Moneda.
- Dimensión Entidad Financiera.
- Hecho Tipo de Cambio.
- Hecho Balance Bancario.
- Primer esquema estrella.

Capítulo 5

Hito 4: Diseño del Modelo Dimensional

5.1. Objetivo

El objetivo de este hito es diseñar el modelo dimensional del Data Warehouse macrofinanciero.

Al finalizar este hito el estudiante será capaz de:

- Identificar el grano de cada tabla de hechos.
- Diferenciar dimensiones y hechos.
- Diseñar un esquema estrella.
- Definir claves de negocio y claves subrogadas.
- Documentar el modelo antes de implementarlo en PostgreSQL.

5.2. Resultado esperado

Al finalizar este hito tendremos definido el modelo lógico del Data Warehouse.

El modelo estará compuesto por:

- `dim_tiempo`
- `dim_moneda`
- `dim_entidad_financiera`

- `fact_tipo_cambio`
- `fact_balance_mensual`

5.3. Paso 1: Entender qué es un modelo dimensional

Un modelo dimensional organiza los datos para facilitar el análisis. Está compuesto por dos tipos principales de tablas:

- **Dimensiones:** describen el contexto del análisis.
- **Hechos:** contienen medidas numéricas que queremos analizar.

Ejemplo:

- La fecha es una dimensión.
- La entidad financiera es una dimensión.
- La moneda es una dimensión.
- La tasa de cambio es una medida.
- Los activos bancarios son una medida.

5.4. Paso 2: Identificar los procesos de negocio

En este proyecto tendremos dos procesos de negocio principales:

1. Seguimiento del mercado cambiario.
2. Seguimiento de balances bancarios mensuales.

Cada proceso generará una tabla de hechos.

5.5. Paso 3: Definir el grano

El grano indica qué representa una fila de una tabla de hechos. Esta decisión es fundamental.

5.5.1. Grano de fact_tipo_cambio

Una fila por fecha y moneda.

Ejemplo:

```
2024-01-01 | USD
2024-01-01 | EUR
2024-01-02 | USD
```

5.5.2. Grano de fact_balance_mensual

Una fila por mes y entidad financiera.

Ejemplo:

```
2024-01-31 | B001
2024-01-31 | B002
2024-02-29 | B001
```

5.6. Paso 4: Definir dimensiones**5.6.1. Dimensión tiempo**

La dimensión tiempo será compartida por ambos hechos.
Esto la convierte en una dimensión conformada.

```
dim\_tiempo
```

```
sk\_tiempo
fecha
anio
mes
anio\_mes
nombre\_mes
trimestre
es\_fin\_de_mes
```

5.6.2. Dimensión moneda

Esta dimensión describe las monedas utilizadas en el mercado cambiario.

```
dim\_moneda

sk\_moneda
moneda\_cod
moneda\_nombre
```

5.6.3. Dimensión entidad financiera

Esta dimensión describe las entidades financieras.

```
dim\_entidad\_financiera

sk\_entidad
entidad\_cod
entidad\_nombre
tipo\_entidad
vigente\_desde
vigente\_hasta
es\_actual
```

La dimensión entidad financiera se diseñará para soportar cambios históricos mediante SCD Tipo 2.

5.7. Paso 5: Definir tablas de hechos

5.7.1. Hecho tipo de cambio

```
fact\_tipo\_cambio

sk\_tiempo
sk\_moneda
tasa_compra
tasa_venta
tasa_promedio
spread
```

Medidas:

- tasa_compra
- tasa_venta
- tasa_promedio
- spread

5.7.2. Hecho balance mensual

fact_balance_mensual

sk_tiempo
 sk_entidad
 activos_totales
 cartera_creditos
 depositos
 patrimonio
 resultado_neto
 depositos_me
 cartera_me

Medidas:

- activos_totales
- cartera_creditos
- depositos
- patrimonio
- resultado_netto
- depositos_me
- cartera_me

5.8. Paso 6: Definir claves

5.8.1. Clave de negocio

La clave de negocio proviene de la fuente original.
 Ejemplos:

- moneda_cod: USD, EUR.
- entidad_cod: B001, B002.
- fecha 2024-01-31.

5.8.2. Clave subrogada

La clave subrogada es creada por el Data Warehouse.
Ejemplos:

- sk_tiempo
- sk_moneda
- sk_entidad

Las tablas de hechos no deben depender directamente de las claves de negocio.

Deben conectarse mediante claves subrogadas.

5.9. Paso 7: Diseñar el esquema estrella

El esquema estrella del proyecto será:

```

dim_tiempo
|
|
dim_moneda ---- fact_tipo_cambio

      dim_tiempo
        |
        |

dim_entidad_financiera ---- fact_balance_mensual

```

La dimensión `dim_tiempo` conecta ambos hechos y permite análisis integrados.

5.10. Paso 8: Crear documento del modelo

Crear el archivo:

docs/modelo_dimensional.md

Contenido sugerido:

```
# Modelo Dimensional
```

```
## Procesos de negocio
```

1. Mercado cambiario
2. Balances bancarios mensuales

```
## Tablas de hechos
```

```
### fact_tipo_cambio
```

Grano:

Una fila por fecha y moneda.

Medidas:

- * tasa_compra
- * tasa_venta
- * tasa_promedio
- * spread

```
### fact_balance_mensual
```

Grano:

Una fila por mes y entidad financiera.

Medidas:

- * activos_totales
- * cartera_creditos
- * depositos
- * patrimonio


```

* resultado_netto
* depositos_me
* cartera_me

## Dimensiones

* dim_tiempo
* dim_moneda
* dim_entidad_financiera

```

5.11. Paso 9: Crear tabla de definición del modelo

Agregar al documento una tabla como la siguiente:

Tabla	Tipo	Grano
dim_tiempo	Dimensión	Una fila por día
dim_moneda	Dimensión	Una fila por moneda
dim_entidad_financiera	Dimensión	Una fila por versión de entidad
fact_tipo_cambio	Hecho	Una fila por fecha y moneda
fact_balance_mensual	Hecho	Una fila por mes y entidad

5.12. Paso 10: Definir indicadores derivados

A partir de este modelo construiremos indicadores como:

- Tipo de cambio promedio.
- Spread cambiario.
- ROA.
- ROE.
- Dolarización de depósitos.
- Dolarización de cartera.
- Concentración bancaria.

Fórmulas principales:

```

tasa_promedio = (tasa_compra + tasa_venta) / 2

spread = tasa_venta - tasa_compra

ROA = resultado_netto / activos_totales

ROE = resultado_netto / patrimonio

dolarizacion_depositos = depositos_me / depositos

dolarizacion_cartera = carterame / carteracreditos

```

5.13. Paso 11: Validar el diseño

Antes de crear las tablas en PostgreSQL, responder:

1. ¿Cada tabla de hechos tiene un grano claro?
2. ¿Cada medida pertenece al grano definido?
3. ¿Las dimensiones describen correctamente los hechos?
4. ¿La dimensión tiempo puede usarse en ambos hechos?
5. ¿La entidad financiera requiere historia?

5.14. Checklist de validación

Antes de continuar verificar:

- ☐ Procesos de negocio identificados.
- ☐ Grano de cada hecho definido.
- ☐ Dimensiones definidas.
- ☐ Hechos definidos.
- ☐ Claves de negocio identificadas.
- ☐ Claves subrogadas definidas.
- ☐ Documento `modelo_dimensional.md` creado.

5.15. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Diseño lógico del Data Warehouse.
- Documento del modelo dimensional.
- Definición de grano.
- Lista de dimensiones.
- Lista de hechos.
- Lista de indicadores derivados.

5.16. Próximo hito

En el Hito 5 implementaremos la primera capa física del Data Warehouse:

- Creación de schemas.
- Creación de tablas staging.
- Preparación de la capa bronze.
- Primer script SQL del modelo.

Capítulo 6

Hito 5: Construcción de la Capa Staging (Bronze)

6.1. Objetivo

El objetivo de este hito es construir la primera capa física del Data Warehouse.

La capa staging será el punto de entrada de todos los datos al sistema. Al finalizar este hito el estudiante será capaz de:

- Crear schemas en PostgreSQL.
- Diseñar tablas de aterrizaje.
- Comprender la función de la capa Bronze.
- Implementar una estrategia de carga desacoplada de las transformaciones.
- Preparar el sistema para recibir datos desde Python.

6.2. Resultado esperado

Al finalizar este hito deberá existir la siguiente estructura lógica:

PostgreSQL

```
+-- staging  
|
```

```
+-- core
|
+-- mart
```

Y dentro del schema staging:

```
staging.tipo_cambio_raw

staging.balance_bancario_raw
```

6.3. ¿Qué es la capa Staging?

La capa staging es el área donde aterrizan los datos provenientes de las fuentes externas.

Su objetivo es almacenar los datos en su forma más cercana al origen.

No se realizan:

- Cálculos.
- Transformaciones complejas.
- Generación de indicadores.
- Limpieza profunda.

La regla general es:

Cargar primero. Transformar después.

6.4. Arquitectura del Data Warehouse

La arquitectura que construiremos será:

```
Fuentes
|
V
Staging (Bronze)
|
V
Core (Silver)
|
V
Mart (Gold)
```

6.5. Paso 1: Crear carpeta para scripts SQL

Verificar:

```
sql/
```

Crear:

```
sql/01_create_schemas.sql
```

6.6. Paso 2: Crear los schemas

Agregar:

```
CREATE SCHEMA IF NOT EXISTS staging ;
```

```
CREATE SCHEMA IF NOT EXISTS core ;
```

```
CREATE SCHEMA IF NOT EXISTS mart ;
```

Guardar.

6.7. Paso 3: Ejecutar el script

Desde psql:

```
\i sql/01_create_schemas.sql
```

Verificar:

```
SELECT schema_name
FROM information_schema.schemata
WHERE schema_name IN
(
    'staging',
    'core',
    'mart'
);
```

Resultado esperado:

```
staging
core
mart
```

6.8. Paso 4: Crear script de tablas staging

Crear:

sql/02_staging_ddl.sql

6.9. Paso 5: Diseñar tabla tipo_cambio_raw

Agregar:

```
CREATE TABLE IF NOT EXISTS
staging.tipo_cambio_raw
(
  fecha TEXT,

  ‘‘‘
moneda TEXT,

tasa_compra TEXT,

tasa_venta TEXT,

archivo_origen TEXT,

cargado_en TIMESTAMP
DEFAULT CURRENT_TIMESTAMP
‘‘‘

);
```

6.10. ¿Por qué usamos TEXT?

Esta es una práctica común en Data Engineering.

Ventajas:

- La carga nunca falla por formato.
- Se preserva el dato original.
- La validación ocurre posteriormente.
- Se facilita el diagnóstico de errores.

6.11. Paso 6: Diseñar tabla balance_bancario_raw

Agregar:

```
CREATE TABLE IF NOT EXISTS
staging.balance_bancario_raw
(
periodo TEXT,

'''
entidad_cod TEXT,

entidad_nombre TEXT,

tipo_entidad TEXT,

activos_totales TEXT,

cartera_creditos TEXT,

depositos TEXT,

patrimonio TEXT,

resultado_neto TEXT,

depositos_me TEXT,

cartera_me TEXT,

archivo_origen TEXT,

cargado_en TIMESTAMP
DEFAULT CURRENT_TIMESTAMP
'''

);
```


6.12. Paso 7: Ejecutar el DDL

Ejecutar:

```
\i sql/02_staging_ddl.sql
```

6.13. Paso 8: Verificar tablas creadas

Consultar:

```
SELECT table_name
FROM information_schema.tables
WHERE table_schema='staging';
```

Resultado esperado:

```
tipo_cambio_raw
```

```
balance_bancario_raw
```

6.14. Paso 9: Inspeccionar estructura

Consultar:

```
SELECT
column_name,
data_type
FROM information_schema.columns
WHERE table_schema='staging'
AND table_name='tipo_cambio_raw';
```

Verificar que todas las columnas fueron creadas correctamente.

6.15. Paso 10: Crear script de prueba

Crear:

```
sql/test_staging.sql
```

Contenido:

```
SELECT *  
FROM staging.tipo_cambio_raw;
```

```
SELECT *  
FROM staging.balance_bancario_raw;
```

Actualmente ambas tablas deben estar vacías.

6.16. Paso 11: Documentar la capa staging

Crear:

docs/staging_design.md

Documentar:

- Nombre de tabla.
- Fuente original.
- Frecuencia.
- Número esperado de columnas.
- Responsable de carga.

Ejemplo:

Tabla:
staging.tipo_cambio_raw

Fuente:
Banco Central

Frecuencia:
Diaria

Objetivo:
Almacenar datos crudos del mercado cambiario.

6.17. Paso 12: Crear consulta de monitoreo

Crear:

sql/monitor_staging.sql

Contenido:

```
SELECT  
COUNT(*) AS total_filas  
FROM staging.tipo_cambio_raw;
```

```
SELECT  
COUNT(*) AS total_filas  
FROM staging.balance_bancario_raw;
```

Esta consulta se utilizará para monitorear futuras cargas.

6.18. Buenas prácticas

Durante este proyecto seguiremos las siguientes reglas:

1. Nunca modificar datos manualmente en staging.
2. Mantener los datos lo más cercanos posible a la fuente.
3. No realizar cálculos en staging.
4. Todas las transformaciones ocurren en la capa core.
5. Conservar metadatos de carga.

6.19. Checklist de validación

Antes de continuar verificar:

- ☐ Schema staging creado.
- ☐ Schema core creado.
- ☐ Schema mart creado.
- ☐ Tabla `tipo_cambio_raw` creada.

- ☐ Tabla `balance_bancario_raw` creada.
- ☐ Scripts SQL almacenados en la carpeta `sql`.
- ☐ Consultas de validación ejecutadas.

6.20. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Arquitectura física inicial del Data Warehouse.
- Schemas creados.
- Tablas staging creadas.
- Scripts SQL documentados.
- Capa Bronze lista para recibir datos.

6.21. Próximo hito

En el Hito 6 construiremos el primer proceso ETL.
Aprenderemos a:

- Leer archivos CSV desde Python.
- Conectarnos a PostgreSQL.
- Cargar información a staging.
- Automatizar la ingesta.
- Validar que los datos fueron cargados correctamente.

Capítulo 7

Hito 5: Construcción de la Capa Staging en DuckDB

7.1. Objetivo

El objetivo de este hito es construir la primera capa física del Data Warehouse utilizando DuckDB.

La capa **staging** será el punto de entrada de todos los datos al sistema. En esta capa almacenaremos los datos provenientes de archivos CSV en una forma cercana a la fuente original.

Al finalizar este hito el estudiante será capaz de:

- Crear schemas en DuckDB.
- Crear tablas de aterrizaje para datos crudos.
- Ejecutar scripts SQL desde Python.
- Preparar la base local para recibir datos desde archivos CSV.
- Mantener la arquitectura **staging ->core ->mart**.

7.2. Resultado esperado

Al finalizar este hito deberán existir tres schemas:

```
staging
core
mart
```

y dos tablas en la capa `staging`:

```
staging.tipo_cambio_raw
```

```
staging.balance_bancario_raw
```

7.3. Paso 1: Crear script de schemas

Crear el archivo:

```
sql/01_create_schemas.sql
```

Contenido:

```
CREATE SCHEMA IF NOT EXISTS staging;
```

```
CREATE SCHEMA IF NOT EXISTS core;
```

```
CREATE SCHEMA IF NOT EXISTS mart;
```

7.4. Paso 2: Crear script para ejecutar SQL

Crear o verificar el archivo:

```
etl/run_sql_file.py
```

Contenido:

```
from db import get_connection
```

```
def run_sql_file(path):
```

```
    '''
```

```
    conn = get_connection()
```

```
    with open(path, "r", encoding="utf-8") as file:  
        sql = file.read()
```

```
    conn.execute(sql)
```

```
    conn.close()
```

```
'''  
  
if __name__ == "__main__":  
  
    '''  
    run_sql_file(  
        "sql/01_create_schemas.sql"  
    )  
  
    print("Script_SQL_ejecutado_correctamente.")  
'''
```

7.5. Paso 3: Ejecutar creación de schemas

Desde la terminal:

```
python etl/run_sql_file.py
```

Salida esperada:

```
Script SQL ejecutado correctamente.
```

7.6. Paso 4: Verificar schemas

Crear el archivo:

```
sql/check_schemas.sql
```

Contenido:

```
SELECT schema_name  
FROM information_schema.schemata  
WHERE schema_name IN  
(  
    'staging',  
    'core',  
    'mart'  
)  
ORDER BY schema_name;
```

Modificar temporalmente `etl/run_sql_file.py` para ejecutar :

CAPÍTULO 7. HITO 5: CONSTRUCCIÓN DE LA CAPA STAGING EN DUCKDB63

```
run_sql_file(  
  "sql/check_schemas.sql"  
)
```

Resultado esperado:

```
core  
mart  
staging
```

7.7. Paso 5: Crear script de tablas staging

Crear:

```
sql/02_staging_ddl.sql
```

7.8. Paso 6: Crear tabla tipo *cambio_raw*

Agregar:

```
CREATE TABLE IF NOT EXISTS staging.tipo_cambio_raw  
(  
  fecha TEXT,  
  
  '''  
  moneda TEXT,  
  
  tasa_compra TEXT,  
  
  tasa_venta TEXT,  
  
  archivo_origen TEXT,  
  
  cargado_en TIMESTAMP  
  ''')  
);
```


7.9. Paso 7: Crear tabla `balance_bancario_raw`

Agregar:

```
CREATE TABLE IF NOT EXISTS staging.balance_bancario_raw
(
  periodo TEXT,

  '''
  entidad_cod TEXT,

  entidad_nombre TEXT,

  tipo_entidad TEXT,

  activos_totales TEXT,

  cartera_creditos TEXT,

  depositos TEXT,

  patrimonio TEXT,

  resultado_netto TEXT,

  depositos_me TEXT,

  cartera_me TEXT,

  archivo_origen TEXT,

  cargado_en TIMESTAMP
  '''
);
```

7.10. Nota sobre tipos de datos

En staging usaremos columnas tipo TEXT.

La idea es cargar primero los datos crudos y validar después.

Esta decisión permite:

- Evitar fallos tempranos por formatos incorrectos.
- Conservar el dato original.
- Separar carga de transformación.
- Diagnosticar errores con mayor facilidad.

7.11. Paso 8: Ejecutar DDL de staging

Modificar temporalmente:

etl/run_sql_file.py

para ejecutar:

```
run_sql_file(  
"sql/02_staging_ddl.sql"  
)
```

Luego ejecutar:

```
python etl/run_sql_file.py
```

7.12. Paso 9: Verificar tablas creadas

Crear:

sql/check_staging_tables.sql

Contenido:

```
SELECT table_schema,  
table_name  
FROM information_schema.tables  
WHERE table_schema = 'staging'  
ORDER BY table_name;
```

Resultado esperado:

```
staging    balance_bancario_raw  
staging    tipo_cambio_raw
```

7.13. Paso 10: Crear script general para inicializar la base

Crear:

etl/init_database.py

Contenido:

```
from db import get_connection

def run_sql(path, conn):

    '''
    with open(path, "r", encoding="utf-8") as file:
        sql = file.read()

    conn.execute(sql)
    '''

def main():

    '''
    conn = get_connection()

    run_sql(
        "sql/01_create_schemas.sql",
        conn
    )

    run_sql(
        "sql/02_staging_ddl.sql",
        conn
    )

    conn.close()

    print("Base DuckDB inicializada correctamente.")
    '''

if __name__ == "__main__":
```

```
main()
```

7.14. Paso 11: Ejecutar inicialización completa

Desde la terminal:

```
python etl/init_database.py
```

Salida esperada:

Base DuckDB inicializada correctamente.

7.15. Paso 12: Crear consulta de monitoreo

Crear:

```
sql/monitor_staging.sql
```

Contenido:

```
SELECT
'tipo_cambio_raw' AS tabla,
COUNT(*) AS total_filas
FROM staging.tipo_cambio_raw
```

```
UNION ALL
```

```
SELECT
'balance_bancario_raw' AS tabla,
COUNT(*) AS total_filas
FROM staging.balance_bancario_raw;
```

Inicialmente ambas tablas deberán tener cero filas.

7.16. Buenas prácticas

Durante este hito seguiremos estas reglas:

1. La base DuckDB vive en data/warehouse.
2. Los schemas separan las capas del Data Warehouse.

CAPÍTULO 7. HITO 5: CONSTRUCCIÓN DE LA CAPA STAGING EN DUCKDB68

3. La capa staging recibe datos crudos.
4. Las transformaciones ocurrirán en core.
5. Las vistas para análisis se construirán en mart.

7.17. Checklist de validación

Antes de continuar verificar:

- ☐ Archivo macrofinanzas.duckdb existe.
- ☐ Schema staging creado.
- ☐ Schema core creado.
- ☐ Schema mart creado.
- ☐ Tabla `tipocambiorawcreada`.
- ☐ Tabla `balancebancariorawcreada`.
- ☐ Script `initdatabase.pyejecutado`.
- ☐ Consulta de monitoreo creada.

7.18. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Base DuckDB inicializada.
- Schemas creados.
- Tablas staging creadas.
- Script de inicialización.
- Capa Bronze lista para recibir datos.

7.19. Próximo hito

En el Hito 6 construiremos el proceso ETL de carga.
Aprenderemos a:

- Leer archivos CSV.
- Cargar datos hacia DuckDB.
- Limpiar la capa staging antes de cada carga.
- Automatizar el flujo de ingesta.
- Verificar conteos de registros cargados.

Capítulo 8

Hito 6: Construcción del Primer Proceso ETL

8.1. Objetivo

El objetivo de este hito es construir el primer flujo completo de carga de datos.

Por primera vez conectaremos:

```
CSV
|
V
Python
|
V
PostgreSQL
```

Al finalizar este hito el estudiante será capaz de:

- Leer archivos CSV mediante Python.
- Conectarse a PostgreSQL utilizando SQLAlchemy.
- Cargar información en la capa staging.
- Automatizar el proceso de carga.
- Validar que los datos fueron cargados correctamente.

8.2. Resultado esperado

Al finalizar este hito los datos contenidos en:

`data/raw/tipo_cambio.csv`

`data/raw/balances.csv`

deberán encontrarse cargados en:

`staging.tipo_cambio_raw`

`staging.balance_bancario_raw`

8.3. Arquitectura del proceso

El flujo que construiremos será:

CSV

|

V

Pandas

|

V

SQLAlchemy

|

V

PostgreSQL

8.4. Paso 1: Verificar archivos fuente

Confirmar la existencia de:

`data/raw/tipo_cambio.csv`

`data/raw/balances.csv`

Verificar que pueden abrirse correctamente.

8.5. Paso 2: Crear módulo de conexión

Verificar el archivo:

etl/db.py

Contenido:

```
from sqlalchemy import create_engine
from dotenv import load_dotenv

import os

load_dotenv()

HOST = os.getenv("DB_HOST")
PORT = os.getenv("DB_PORT")
DB = os.getenv("DB_NAME")
USER = os.getenv("DB_USER")
PASSWORD = os.getenv("DB_PASSWORD")

connection_string = (
    f"postgresql+psycopg2://"
    f"{USER}:{PASSWORD}@{HOST}:{PORT}/{DB}"
)

engine = create_engine(
    connection_string
)
```

8.6. Paso 3: Crear script de carga

Crear:

etl/load_staging.py

8.7. Paso 4: Importar librerías

Agregar:

CAPÍTULO 8. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL73

```
import pandas as pd

from db import engine
```

8.8. Paso 5: Leer tipo de cambio

```
Agregar:

fx = pd.read_csv(
    "data/raw/tipo_cambio.csv"
)

print(
    f"Filas_tipo_cambio:{len(fx)}"
)
```

8.9. Paso 6: Leer balances

```
Agregar:

balances = pd.read_csv(
    "data/raw/balances.csv"
)

print(
    f"Filas_balances:{len(balances)}"
)
```

8.10. Paso 7: Agregar metadatos

```
Agregar:

fx["archivo_origen"] = (
    "tipo_cambio.csv"
)

balances["archivo_origen"] = (
    "balances.csv"
)
```

Estos metadatos permiten rastrear el origen de cada carga.

8.11. Paso 8: Limpiar staging antes de cargar

Crear:

sql/truncate_staging.sql

Contenido:

```
TRUNCATE TABLE
staging.tipo_cambio_raw;

TRUNCATE TABLE
staging.balance_bancario_raw;
```

Esta estrategia garantiza idempotencia.

8.12. Paso 9: Ejecutar truncado desde Python

Agregar:

```
from sqlalchemy import text

with engine.begin() as conn:

    '''
    conn.execute(
        text(
            """
            TRUNCATE TABLE
            staging.tipo_cambio_raw;

            TRUNCATE TABLE
            staging.balance_bancario_raw;
            """
        )
    )
    '''
```

8.13. Paso 10: Cargar tipo de cambio

Agregar:

```
fx.to_sql(  
    "tipo_cambio_raw",  
    con=engine,  
    schema="staging",  
    if_exists="append",  
    index=False  
)
```

8.14. Paso 11: Cargar balances

Agregar:

```
balances.to_sql(  
    "balance_bancario_raw",  
    con=engine,  
    schema="staging",  
    if_exists="append",  
    index=False  
)
```

8.15. Paso 12: Confirmar carga

Agregar:

```
print(  
    "Carga_ completada."  
)
```

8.16. Versión completa del script

El archivo completo debe verse así:

```
import pandas as pd  
  
from sqlalchemy import text  
  
from db import engine  
  
fx = pd.read_csv(  

```

CAPÍTULO 8. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL76

```
"data/raw/tipo_cambio.csv"
)

balances = pd.read_csv(
"data/raw/balances.csv"
)

fx["archivo_origen"] = (
"tipo_cambio.csv"
)

balances["archivo_origen"] = (
"balances.csv"
)

with engine.begin() as conn:

    '''
    conn.execute(
        text(
            """
            TRUNCATE TABLE
            staging.tipo_cambio_raw;

            TRUNCATE TABLE
            staging.balance_bancario_raw;
            """
        )
    )

    '''

fx.to_sql(
"tipo_cambio_raw",
con=engine,
schema="staging",
if_exists="append",
index=False
)

balances.to_sql(
```

CAPÍTULO 8. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL

```
"balance_bancario_raw",
con=engine,
schema="staging",
if_exists="append",
index=False
)

print("Carga completada.")
```

8.17. Paso 13: Ejecutar ETL

Desde terminal:

```
python etl/load_staging.py
```

Salida esperada:

Carga completada.

8.18. Paso 14: Verificar en PostgreSQL

Consultar:

```
SELECT COUNT(*)
FROM staging.tipo_cambio_raw;
```

Consultar:

```
SELECT COUNT(*)
FROM staging.balance_bancario_raw;
```

Los conteos deben coincidir con los CSV.

8.19. Paso 15: Inspeccionar datos

Consultar:

```
SELECT *
FROM staging.tipo_cambio_raw
LIMIT 10;
```

Consultar:

CAPÍTULO 8. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL78

```
SELECT *
FROM staging.balance_bancario_raw
LIMIT 10;
```

8.20. Paso 16: Crear script de validación

Crear:

sql/check_load.sql

Contenido:

```
SELECT
COUNT(*) AS total_fx
FROM staging.tipo_cambio_raw;

SELECT
COUNT(*) AS total_balances
FROM staging.balance_bancario_raw;
```

8.21. Paso 17: Crear orquestador

Crear:

etl/run_pipeline.py

Contenido inicial:

```
import subprocess

subprocess.run(
[
"python",
"etl/load_staging.py"
]
)
```

Este archivo será el punto de entrada de todo el pipeline.

8.22. Buenas prácticas

Durante este proyecto seguiremos las siguientes reglas:

1. El ETL debe ser reproducible.
2. La carga debe ser idempotente.
3. No modificar datos manualmente.
4. Validar cada carga.
5. Mantener trazabilidad mediante metadatos.

8.23. Checklist de validación

Antes de continuar verificar:

- ☐ Python puede leer ambos CSV.
- ☐ Python puede conectarse a PostgreSQL.
- ☐ Staging se limpia correctamente.
- ☐ Los datos son cargados.
- ☐ Los conteos coinciden.
- ☐ El script puede ejecutarse múltiples veces.

8.24. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Script de carga funcional.
- Datos cargados en staging.
- Validaciones básicas.
- Pipeline reproducible.
- Primer flujo ETL completo.

8.25. Próximo hito

En el Hito 7 construiremos la capa Core.
Crearemos:

- Dimensión Tiempo.
- Dimensión Moneda.
- Dimensión Entidad Financiera.
- Claves subrogadas.
- Primera transformación desde staging hacia el modelo dimensional.

Capítulo 9

Hito 6: Construcción del Primer Proceso ETL con DuckDB

9.1. Objetivo

El objetivo de este hito es construir el primer flujo completo de carga de datos utilizando DuckDB.

Por primera vez conectaremos:

```
CSV
|
V
Python
|
V
DuckDB
```

Al finalizar este hito el estudiante será capaz de:

- Leer archivos CSV mediante Pandas.
- Conectarse a DuckDB desde Python.
- Cargar información a la capa staging.
- Automatizar el proceso de carga.
- Validar que los datos fueron cargados correctamente.

9.2. Resultado esperado

Al finalizar este hito los datos contenidos en:

`data/raw/tipo_cambio.csv`

`data/raw/balances.csv`

deberán encontrarse cargados en:

`staging.tipo_cambio_raw`

`staging.balance_bancario_raw`

dentro de DuckDB.

9.3. Arquitectura del proceso

El flujo construido será:

```
CSV
|
V
Pandas
|
V
DuckDB
```

9.4. Paso 1: Verificar archivos fuente

Confirmar la existencia de:

`data/raw/tipo_cambio.csv`

`data/raw/balances.csv`

9.5. Paso 2: Verificar conexión

Verificar:

CAPÍTULO 9. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL CON DUCKDB83

etl/db.py

Contenido:

```
import duckdb

DB_PATH = (
    "data/warehouse/"
    "macrofinanzas.duckdb"
)

def get_connection():
    """
    return duckdb.connect(
        DB_PATH
    )
    """
```

9.6. Paso 3: Crear script de carga

Crear:

etl/load_staging.py

9.7. Paso 4: Importar librerías

Agregar:

```
import pandas as pd

from db import get_connection
```

9.8. Paso 5: Leer tipo de cambio

Agregar:

```
fx = pd.read_csv(
    "data/raw/tipo_cambio.csv"
)
```

```
print(  
f"Filas_FX: {len(fx)}"  
)
```

9.9. Paso 6: Leer balances

```
Agregar:  
  
balances = pd.read_csv(  
"data/raw/balances.csv"  
)  
  
print(  
f"Filas_balances: {len(balances)}"  
)
```

9.10. Paso 7: Agregar metadatos

```
Agregar:  
  
fx["archivo_origen"] = (  
"tipo_cambio.csv"  
)  
  
balances["archivo_origen"] = (  
"balances.csv"  
)  
  
Agregar timestamp:  
  
from datetime import datetime  
  
fx["cargado_en"] = (  
datetime.now()  
)  
  
balances["cargado_en"] = (  
datetime.now()  
)
```

9.11. Paso 8: Conectarse a DuckDB

Agregar:

```
conn = get_connection()
```

9.12. Paso 9: Limpiar staging

Agregar:

```
conn.execute(
    """
    DELETE FROM
    staging.tipo_cambio_raw;
    """
)

conn.execute(
    """
    DELETE FROM
    staging.balance_bancario_raw;
    """
)
```

Esta estrategia garantiza que la carga sea reproducible.

9.13. Paso 10: Registrar DataFrames

DuckDB permite consultar directamente DataFrames.

Agregar:

```
conn.register(
    "fx_df",
    fx
)

conn.register(
    "balances_df",
    balances
)
```

9.14. Paso 11: Cargar tipo de cambio

Agregar:

```
conn.execute(  
    """  
    INSERT INTO  
    staging.tipo_cambio_raw  
  
    SELECT *  
    FROM fx_df;  
    """  
)
```

9.15. Paso 12: Cargar balances

Agregar:

```
conn.execute(  
    """  
    INSERT INTO  
    staging.balance_bancario_raw  
  
    SELECT *  
    FROM balances_df;  
    """  
)
```

9.16. Paso 13: Verificar conteos

Agregar:

```
result_fx = conn.execute(  
    """  
    SELECT COUNT(*)  
    FROM staging.tipo_cambio_raw  
    """  
)  
result_fx.fetchone()[0]  
  
result_balances = conn.execute(  
    """  
    SELECT COUNT(*)  
    FROM staging.balance_bancario_raw  
    """  
)  
result_balances.fetchone()[0]
```

CAPÍTULO 9. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL CON DUCKDB87

```
"""
SELECT COUNT(*)
FROM staging.balance_bancario_raw
"""
).fetchone()[0]

print(
    f"Filas staging FX: {result_fx}"
)

print(
    f"Filas staging balances: {result_balances}"
)
```

9.17. Paso 14: Cerrar conexión

Agregar:

```
conn.close()
```

9.18. Versión completa del script

```
import pandas as pd

from datetime import datetime

from db import get_connection

fx = pd.read_csv(
    "data/raw/tipo_cambio.csv"
)

balances = pd.read_csv(
    "data/raw/balances.csv"
)

fx["archivo_origen"] = (
    "tipo_cambio.csv"
```


CAPÍTULO 9. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL CON DUCKDB88

```
)

balances["archivo_origen"] = (
    "balances.csv"
)

fx["cargado_en"] = (
    datetime.now()
)

balances["cargado_en"] = (
    datetime.now()
)

conn = get_connection()

conn.execute(
    """
DELETE FROM
staging.tipo_cambio_raw;
    """
)

conn.execute(
    """
DELETE FROM
staging.balance_bancario_raw;
    """
)

conn.register(
    "fx_df",
    fx
)

conn.register(
    "balances_df",
    balances
)
```

CAPÍTULO 9. HITO 6: CONSTRUCCIÓN DEL PRIMER PROCESO ETL CON DUCKDB89

```
conn.execute(
    """
INSERT INTO
staging.tipo_cambio_raw

SELECT *
FROM fx_df;
    """
)

conn.execute(
    """
INSERT INTO
staging.balance_bancario_raw

SELECT *
FROM balances_df;
    """
)

result_fx = conn.execute(
    """
SELECT COUNT(*)
FROM staging.tipo_cambio_raw
    """
).fetchone()[0]

result_balances = conn.execute(
    """
SELECT COUNT(*)
FROM staging.balance_bancario_raw
    """
).fetchone()[0]

print(
    f"Filas staging_FX: {result_fx}"
)

print(
    f"Filas staging_balances: {result_balances}"
)
```

```
)  
  
conn.close()  
  
print("Carga_ completada.")
```

9.19. Paso 15: Ejecutar ETL

Desde terminal:

```
python etl/load_staging.py
```

Salida esperada:

```
Filas FX: 100  
Filas balances: 50  
  
Filas staging FX: 100  
Filas staging balances: 50  
  
Carga completada.
```

9.20. Paso 16: Crear consulta de monitoreo

Crear:

```
sql/monitor_staging.sql
```

Contenido:

```
SELECT  
'tipo_cambio_raw' AS tabla,  
COUNT(*) AS total_filas  
FROM staging.tipo_cambio_raw  
  
UNION ALL  
  
SELECT  
'balance_bancario_raw' AS tabla,  
COUNT(*) AS total_filas  
FROM staging.balance_bancario_raw;
```

9.21. Paso 17: Ejecutar consulta

Desde Python:

```
result = conn.execute(  
    open(  
        "sql/monitor_staging.sql"  
    ).read()  
).fetchdf()  
  
print(result)
```

Resultado esperado:

tabla	total_filas
0 tipo_cambio_raw	100
1 balance_bancario_raw	50

9.22. Paso 18: Crear orquestador

Crear:

etl/run_pipeline.py

Contenido inicial:

```
import subprocess  
  
subprocess.run(  
    [  
        "python",  
        "etl/load_staging.py"  
    ],  
    check=True  
)  
  
print(  
    "Pipeline_✓ejecutado_✓correctamente."  
)
```

9.23. Buenas prácticas

Durante este hito seguiremos las siguientes reglas:

1. Todas las cargas deben ser reproducibles.
2. No modificar tablas staging manualmente.
3. Mantener metadatos de carga.
4. Validar conteos después de cada carga.
5. Cerrar conexiones al finalizar.

9.24. Checklist de validación

- ☐ CSV leídos correctamente.
- ☐ Conexión DuckDB funcional.
- ☐ Tablas staging limpiadas.
- ☐ Datos cargados.
- ☐ Conteos validados.
- ☐ Script `monitor_staging.sql` ejecutado.
- ☐ Pipeline reproducible.

9.25. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Primer proceso ETL funcional.
- Datos cargados en staging.
- Consulta de monitoreo.
- Orquestador inicial.
- Flujo completo CSV → Python → DuckDB.

9.26. Próximo hito

En el Hito 7 construiremos la capa Core.
Crearemos:

- Dimensión Tiempo.
- Dimensión Moneda.
- Dimensión Entidad Financiera.
- Claves subrogadas.
- Primera transformación desde staging hacia el modelo dimensional.

Capítulo 10

Hito 7: Construcción de la Capa Core y Dimensiones en DuckDB

10.1. Objetivo

El objetivo de este hito es construir la capa core del Data Warehouse.

En esta capa comenzaremos a transformar los datos crudos almacenados en staging en estructuras analíticas organizadas siguiendo principios de modelado dimensional.

Al finalizar este hito el estudiante será capaz de:

- Crear dimensiones en DuckDB.
- Comprender el uso de claves subrogadas.
- Construir una dimensión tiempo.
- Construir una dimensión moneda.
- Construir una dimensión entidad financiera.
- Poblar dimensiones a partir de los datos de staging.
- Preparar la base para construir las tablas de hechos.

10.2. Resultado esperado

Al finalizar este hito deberán existir:

```
core.dim_tiempo
```

```
core.dim_moneda
```

```
core.dim_entidad_financiera
```

Estas dimensiones serán utilizadas posteriormente por las tablas de hechos.

10.3. Arquitectura del hito

El flujo de transformación será:

```
staging
```

```
|
```

```
V
```

```
core.dim_tiempo
```

```
core.dim_moneda
```

```
core.dim_entidad_financiera
```

10.4. Paso 1: Crear script de dimensiones

Crear:

```
sql/03_dimensions_ddl.sql
```

10.5. Paso 2: Crear dimensión tiempo

Agregar:

```
CREATE TABLE IF NOT EXISTS core.dim_tiempo  
(  
  sk_tiempo INTEGER PRIMARY KEY,
```



```
'''
fecha DATE NOT NULL,

anio INTEGER,

mes INTEGER,

trimestre INTEGER,

anio_mes INTEGER,

nombre_mes VARCHAR,

es_fin_de_mes BOOLEAN
'''

);
```

10.6. Paso 3: Crear dimensión moneda

Agregar:

```
CREATE TABLE IF NOT EXISTS core.dim_moneda
(
sk_moneda INTEGER PRIMARY KEY,

'''
moneda_cod VARCHAR,

moneda_nombre VARCHAR
'''

);
```

10.7. Paso 4: Crear dimensión entidad financiera

Agregar:

```
CREATE TABLE IF NOT EXISTS
```

```
core.dim_entidad_financiera
(
sk_entidad INTEGER PRIMARY KEY,

'''
entidad_cod VARCHAR,

entidad_nombre VARCHAR,

tipo_entidad VARCHAR,

vigente_desde DATE,

vigente_hasta DATE,

es_actual BOOLEAN
'''

);
```

10.8. Paso 5: Ejecutar DDL

Desde Python:

```
from db import get_connection

conn = get_connection()

with open(
    "sql/03_dimensions_ddl.sql",
    "r",
    encoding="utf-8"
) as file:

    '''
    conn.execute(
        file.read()
    )
    '''
```

```
conn.close()
```

10.9. Paso 6: Crear script de carga

Crear:

```
sql/04_load_dimensions.sql
```

10.10. Paso 7: Limpiar dimensiones

Agregar:

```
DELETE FROM
core.dim_entidad_financiera;
```

```
DELETE FROM
core.dim_moneda;
```

```
DELETE FROM
core.dim_tiempo;
```

10.11. Paso 8: Poblar dimensión tiempo

Agregar:

```
INSERT INTO core.dim_tiempo
```

```
SELECT
```

```
‘‘‘
CAST(
    strftime(
        fecha,
        ‘%Y%m%d’
    ) AS INTEGER
) AS sk_tiempo,
fecha,
```

```
year(fecha) AS anio,

month(fecha) AS mes,

quarter(fecha) AS trimestre,

CAST(
    strftime(
        fecha,
        '%Y%m'
    ) AS INTEGER
) AS anio_mes,

monthname(fecha)
    AS nombre_mes,

fecha =
last_day(fecha)
    AS es_fin_de_mes
'',

FROM generate_series(
DATE '2022-01-01',
DATE '2024-12-31',
INTERVAL 1 DAY
) t(fecha);
```

10.12. Explicación

DuckDB posee una función muy útil:

```
generate_series()
```

que permite generar calendarios completos sin necesidad de archivos externos.

10.13. Paso 9: Poblar dimensión moneda

Agregar:

CAPÍTULO 10. HITO 7: CONSTRUCCIÓN DE LA CAPA CORE Y DIMENSIONES EN DUCKDB100

```
INSERT INTO core.dim_moneda

SELECT

'''
ROW_NUMBER()
OVER(
    ORDER BY moneda
) AS sk_moneda,

moneda AS moneda_cod,

CASE

    WHEN moneda='USD'
    THEN 'Dolar_estadounidense'

    WHEN moneda='EUR'
    THEN 'Euro'

    ELSE moneda

END AS moneda_nombre
'''

FROM
(
SELECT DISTINCT
moneda
FROM staging.tipo_cambio_raw
) x;
```

10.14. Paso 10: Poblar dimensión entidad financiera

Agregar:

```
INSERT INTO
core.dim_entidad_financiera
```

CAPÍTULO 10. HITO 7: CONSTRUCCIÓN DE LA CAPA CORE Y DIMENSIONES EN DUCKDB10

```
SELECT

    '','','
ROW_NUMBER()
OVER(
    ORDER BY entidad_cod
) AS sk_entidad,

entidad_cod,

entidad_nombre,

tipo_entidad,

DATE '2022-01-01'
    AS vigente_desde,

DATE '9999-12-31'
    AS vigente_hasta,

TRUE
    AS es_actual
    '','','

FROM
(
SELECT DISTINCT

    '','','
    entidad_cod,

    entidad_nombre,

    tipo_entidad

FROM
    staging.balance_bancario_raw
    '','','
```

```
) x;
```

10.15. Nota sobre SCD Tipo 2

En esta primera versión no implementaremos todavía una dimensión histórica completa.

La lógica será:

- Una fila por entidad.
- Una sola versión vigente.
- Sin cambios históricos.

En una versión posterior agregaremos:

- Versionamiento.
- Fechas de vigencia.
- SCD Tipo 2 completo.

10.16. Paso 11: Ejecutar carga

Crear:

etl/load_dimensions.py

Contenido:

```
from db import get_connection

conn = get_connection()

with open(
    "sql/04_load_dimensions.sql",
    "r",
    encoding="utf-8"
) as file:

    '''
```

```
sql = file.read()
'''

conn.execute(sql)

conn.close()

print(
    "Dimensiones cargadas."
)
```

10.17. Paso 12: Verificar dimensión tiempo

Crear:

sql/check_dim_tiempo.sql

```
SELECT *
FROM core.dim_tiempo
LIMIT 10;
```

10.18. Paso 13: Verificar dimensión moneda

```
SELECT *
FROM core.dim_moneda;
```

Resultado esperado:

```
USD
EUR
```

10.19. Paso 14: Verificar dimensión entidad financiera

```
SELECT *
FROM core.dim_entidad_financiera;
```


10.20. Paso 15: Crear consulta de monitoreo

Crear:

sql/check_dimensions.sql

Contenido:

```
SELECT

'''
'dim_tiempo' AS tabla,

COUNT(*) AS total_filas
'''

FROM core.dim_tiempo

UNION ALL

SELECT

'''
'dim_moneda',

COUNT(*)
'''

FROM core.dim_moneda

UNION ALL

SELECT

'''
'dim_entidad_financiera',

COUNT(*)
'''

FROM core.dim_entidad_financiera;
```

10.21. Paso 16: Ejecutar monitoreo

Resultado esperado:

```
dim_tiempo  
  
dim_moneda  
  
dim_entidad_financiera  
  
con conteos positivos.
```

10.22. Paso 17: Integrar al pipeline

Actualizar:

```
etl/run_pipeline.py  
  
import subprocess  
  
subprocess.run(  
    [  
        "python",  
        "etl/load_staging.py"  
    ],  
    check=True  
)  
  
subprocess.run(  
    [  
        "python",  
        "etl/load_dimensions.py"  
    ],  
    check=True  
)  
  
print(  
    "Pipeline_ejecutado_correctamente."  
)
```

10.23. Buenas prácticas

Durante este hito seguiremos las siguientes reglas:

1. Las dimensiones siempre se construyen desde staging.
2. Las claves subrogadas pertenecen al Data Warehouse.
3. La dimensión tiempo debe ser reutilizable.
4. La dimensión entidad debe ser preparada para soportar SCD.
5. Las cargas deben ser reproducibles.

10.24. Checklist de validación

- ☐ Dimensión tiempo creada.
- ☐ Dimensión moneda creada.
- ☐ Dimensión entidad creada.
- ☐ Dimensión tiempo poblada.
- ☐ Dimensión moneda poblada.
- ☐ Dimensión entidad poblada.
- ☐ Script de monitoreo creado.
- ☐ Pipeline actualizado.

10.25. Entregable

Al finalizar este hito el estudiante deberá disponer de:

- Tres dimensiones pobladas.
- Scripts SQL documentados.
- Script de carga automatizado.
- Pipeline funcional.
- Capa Core parcialmente construida.

10.26. Próximo hito

En el Hito 8 construiremos las tablas de hechos.
Aprenderemos a:

- Resolver claves subrogadas.
- Crear $\text{fact}_{\text{tipo}_{\text{ambio}}}$.
- Crear $\text{fact}_{\text{balance}_{\text{mensual}}}$.
- Calcular medidas derivadas.
- Validar el grano de cada hecho.